



Machine Learning para Secadoras

Materia:

Inteligencia Artificial Avanzada

Integrantes:

José Antonio Miranda Baños

Campus: Querétaro.

Fecha: 24 de agosto de 2024

Machine Learning Para Secadoras

José Antonio Miranda Baños
IRS, Instituto Tecnológico y de Estudios
Superiores de Monterrey
(Campus QRT)
Qrt, Mx
A0161795@tec.mx

Abstract—

Keywords— Machine Learnig, Regresión logística,

I. INTRODUCCIÓN

Esta década (2020) ha sido definitivamente la década del Machine Learning; pareciera que todas las empresas buscan implementar esta tecnología en cada uno de sus productos. El Machine Learning ha demostrado ser una herramienta poderosa en diversas industrias, desde la automotriz hasta la salud. En el contexto de los electrodomésticos, particularmente en las secadoras, el uso de Machine Learning abre nuevas posibilidades para mejorar la eficiencia, optimizar el rendimiento y personalizar la experiencia del usuario.

Las secadoras tradicionales han evolucionado en términos de diseño y funcionalidad, pero la integración de algoritmos de Machine Learning promete llevar estas mejoras a un nuevo nivel. Con la capacidad de analizar grandes volúmenes de datos en tiempo real, las secadoras equipadas con Machine Learning podrán predecir patrones de uso, ajustar los ciclos de secado según las necesidades específicas de cada carga y anticipar problemas potenciales antes de que ocurran.

De modo que es solo cuestión de tiempo para empezar a ver más productos del tipo electrodoméstico con integraciones de Machine Learning

Este artículo explora cómo el Machine Learning puede transformar las secadoras, revisando aplicaciones actuales, desafíos técnicos y perspectivas futuras. Además, se discute cómo la implementación de estas tecnologías no solo puede incrementar la eficiencia energética, sino también ofrecer una mayor comodidad y cuidado para las prendas. A través de un análisis detallado de estudios de caso y avances recientes, se busca proporcionar una visión integral de cómo el Machine Learning está redefiniendo el sector de los electrodomésticos.

II. DESARROLLO

A. ¿Como funciona tu Secadora?

Aunque la pregunta puede parecer sencilla, entender el funcionamiento de una secadora es crucial para abordar cuestiones más profundas como el daño potencial a la ropa o la eficiencia en el manejo de grandes volúmenes de prendas. Las secadoras, a pesar de su diseño aparentemente simple, involucran una serie de procesos complejos que afectan tanto el resultado del secado como la durabilidad de las prendas.

El funcionamiento de una secadora es relativamente sencillo y se puede entender cómo que queremos separar el

agua que quedo después de que la lavadora centrifugara nuestra ropa. La mejor solución para esto es calentarla para evaporar esta agua y extraer el vapor para ir lentamente reduciendo la cantidad de agua en nuestra ropa. Ahora hay muchas otras cosas involucradas que no considere en el resumen rápido de como secar ropa. Por ejemplo, no tomamos en cuenta que la ropa no puede estar junta o sino esta se acumula y esta no se llega a secar, que no podemos hacer girar el tambor muy rápido sino el aire no alcanza a llevarse nada de la humedad y la obstrucción del escape de tu secadora.

Estos y otros varios factores llegan a afectar el ciclo de secado de tu secadora y dañar tu ropa, por lo que no saber usar bien tu secadora afectara la vida útil de tus prendas.

B. Machine Learning para Secadoras

Al comenzar este proyecto, no anticipé la magnitud del impacto que el Machine Learning (ML) podría tener en las secadoras. Inicialmente, podría parecer que no hay necesidad de implementar modelos de ML en un electrodoméstico como una secadora, especialmente si consideramos que, a diferencia de una estufa, no estamos presentes para supervisar su funcionamiento. Sin embargo, al profundizar en el análisis, se vuelve evidente que las secadoras, al ser herramientas "Non-Supervised", se benefician enormemente de la integración de modelos de ML.

1. Definición de "Non-Supervised" y "Supervised"

Non-Supervised: En el contexto de los electrodomésticos, una máquina "Non-Supervised" es aquella que realiza una tarea de manera autónoma sin la necesidad de supervisión continua. Un ejemplo de esto es la secadora. Una vez que introduces la ropa y seleccionas un programa, la secadora completa el ciclo sin intervención adicional. Esta falta de supervisión directa la hace candidata ideal para la integración de ML, que puede optimizar su funcionamiento y mejorar los resultados sin la necesidad de monitoreo constante.

Supervised: En contraste, herramientas "Supervised" como la estufa requieren la presencia del usuario para ajustar parámetros en tiempo real. Dado que el usuario está activamente involucrado en el proceso (como cocinar), no hay una necesidad inmediata de implementar ML para gestionar la operación del aparato, ya que el control manual y la supervisión directa cumplen esa función.

III. IMPLEMENTACIÓN

El desafío es claro: desarrollar la secadora ideal, una máquina que pueda secar eficientemente cualquier tipo de ropa sin importar su naturaleza, al punto de que entregar la ropa doblada sea casi una muestra de vanidad. Para alcanzar este objetivo, nos proponemos utilizar técnicas avanzadas de Machine Learning, específicamente una regresión logística, para identificar y ajustar el ciclo de secado adecuado para cada tipo de prenda.

1. Definiendo la Secadora Ideal

El concepto de la secadora ideal implica una máquina capaz de adaptar su ciclo de secado a las características específicas de cada carga de ropa, asegurando resultados óptimos sin necesidad de intervención manual. Esto requiere un sistema que pueda:

Detectar el Tipo de Prenda: Identificar las características de las diferentes prendas (tipo de tejido, grosor, etc.) para ajustar el ciclo de secado en consecuencia.

Ajustar el Ciclo de Secado: Modificar parámetros como la temperatura y la duración del ciclo según las necesidades específicas de la ropa.

Optimizar el Desempeño: Asegurar que cada ciclo de secado sea eficiente en términos de tiempo y consumo energético, manteniendo la calidad de las prendas.

2. Implementación de la Regresión Logística

Para alcanzar estos objetivos, implementaremos un modelo de regresión logística, que es adecuado para la clasificación binaria y multiclase. Este modelo ayudará a identificar el tipo de ciclo que la secadora debe utilizar basándose en las características de las prendas. Los pasos clave en la implementación son:

Recopilación de Datos: Utilizaremos conjuntos de datos reales proporcionados por la empresa MABE. Estos datos incluyen información detallada sobre diferentes tipos de prendas y los ciclos de secado asociados, permitiendo al modelo aprender las relaciones entre las características de la ropa y los ciclos de secado óptimos.

Preparación de Datos: Los datos se procesarán para asegurar que estén limpios y bien estructurados. Esto incluye la normalización de variables y el manejo de datos faltantes o anomalías.

Entrenamiento del Modelo: Se entrenará la regresión logística utilizando los datos recopilados. El modelo aprenderá a clasificar las prendas en función de sus características y predecir el ciclo de secado más adecuado.

Evaluación del Modelo: Se evaluará la precisión del modelo utilizando métricas de rendimiento como la exactitud, la precisión y la recuperación. Esto ayudará a ajustar los parámetros y mejorar la capacidad del modelo para generalizar a nuevas muestras.

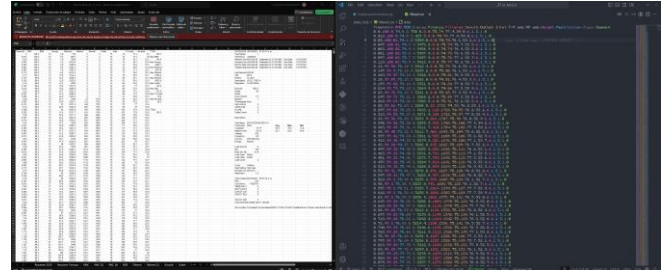
3. Beneficios y Futuro

La implementación de la regresión logística en la secadora no solo promete mejorar la eficiencia del secado y la protección de las prendas, sino que también abre la puerta a futuras mejoras. Con el tiempo, el modelo puede refinarse y ajustarse utilizando datos adicionales y técnicas avanzadas de

Machine Learning, como el aprendizaje profundo, para mejorar aún más la precisión y la adaptabilidad de la secadora.

A. Preparación de los Datos

Aunque agradecemos mucho los datos brindados por la empresa MABE, reconocemos que el formato que manejan es difícil de procesar, por lo que tuvimos que convertirlo y depurarlo para conseguir una serie de CSVs con los que poder alimentar a nuestro algoritmo.



Podemos ver el antes y después de los datos ya extraídos. Esta no fue la única transformación que hicimos de los datos, primero que nada, analizamos el comportamiento de algunas variables de interés, la Obstrucción, Inlet, Outlet y RMC.

a) *Inlet:* La temperatura generada por la secadora, tiene un setpoint y se caracteriza por los picos que genera según el RMC.

b) *Outlet:* Es la temperatura que sale de la secadora, nos indica que tanta humedad se esta retirando de nuestra secadora.

c) *RMC:* Es la humedad que hay dentro de la secadora

d) *La Obstrucción:* Es la medición del flujo de aire del escape de a la secadora, 3.5 se refiere una restricción abierta y 1.5 a una cerrada.

Revisando el comportamiento de Inlet y Outlet en función del tiempo, nos dimos cuenta que los primeros 2 minutos de la secadora son muy parecido, puesto que trata de llegar al set point de temperatura, por lo que no hay mucho que analizar, eh incluso podría llegar a sesgar el modelo. Por lo que cortamos los primeros 2.5 minutos.

Nos interesa saber la relación entre Inlet y Outlet por lo que creamos una nueva casilla resultado de esta relación.

Queremos conocer el cambio de Inlet y el de Outlet por lo que hacemos una nueva casilla con la diferencia entre su estancia actual y la pasada, de este modo podemos inferir los picos y los valles que se generan durante el ciclo.

Ahora como nos interesa poder analizar el mas mínimo cambio de estas variables, nos parece buena idea poner al cuadrado estas diferencias y las variables para que su cambio llegue a tener mas peso en sus parámetros.

```
43 # Agregar relacion entre las variables
44 df['out/in'] = df['Outlet']/df['Inlet']
45 # Agregar el diferencial de Inlet
46 df['Delta T in'] = (df['Inlet'] - df['Outlet']).shift(1)**2
47 # Agregar el diferencial de Outlet
48 df['Delta T out'] = (df['Outlet'] - df['Outlet']).shift(1)**2
49
50 df['Delta RDBOutlet'] = (df['Outlet']-df['RDB'])**2
51 # Agregar el cuadrado
52 df['Inlet'] = df['Inlet']**2
53 df['Outlet'] = df['Outlet']**2
54
```

B. Entrenamiento

En cuanto a nuestra implementación de regresión logística podemos resaltar que ocupamos operaciones matriciales para poder acelerar el entrenamiento de nuestra regresión. Aunque

nuestra función no llega a darnos valores exactos de 0 y 1 para diferenciar entre clases, solucionamos esto en la parte de pruebas, donde redondeamos la salida de nuestra red, aumentando considerablemente el accuracy de nuestro modelo.

C. Evaluación del Modelo

REFERENCIAS

- [1] Referencia [1]
- [2] Referencia [2]